


# BioEmu

Emulación de ensambles conformacionales de proteínas con IA generativa

**Caso de estudio: la quimera LBPCheY**



*Modelo 0 de AlphaFold3 · LBP en gris, CheY en naranja*

# Contenido

**01**

## El problema

Por qué una sola estructura no basta

**02**

## Qué es BioEmu

Origen, alcance y entrenamiento

**03**

## Cómo funciona

De la secuencia al ensamble

**04**

## Entradas y salidas

Parámetros y archivos generados

**05**

## Caso LBPCheY

Pipeline completo y resultados

**06**

## Conclusiones

Limitaciones y siguientes pasos

# Una estructura no describe cómo se mueve una proteína



## Predicción estática

*AlphaFold y similares*

- Una conformación por modelo
- Muy precisa para el estado más probable
- No informa sobre poblaciones ni flexibilidad



## Dinámica molecular

*Simulación física*

- Ensamble con base física
- Cambios lentos ( $\mu\text{s}$ – $\text{ms}$ ) cuestan semanas de GPU
- Difícil de escalar a muchas proteínas



## BioEmu

*Emulador generativo*

- Ensamble de equilibrio desde la secuencia
- Miles de estructuras por hora en una GPU
- Muestras estadísticamente independientes

# BioEmu: el ensamble de equilibrio desde la secuencia

Modelo generativo de difusión de Microsoft Research (Lewis et al., Science 2025).

Recibe una secuencia de una sola cadena y produce muestras independientes de su ensamble de equilibrio. Captura movimientos funcionales como bolsillos crípticos, desplegamiento local y rearrreglos entre dominios.

**Código y pesos abiertos (licencia MIT):**

[github.com/microsoft/bioemu](https://github.com/microsoft/bioemu)

**>200 ms**

de simulaciones de MD  
integradas en el  
entrenamiento

**~1 kcal/mol**

de error en energías libres  
relativas frente a MD y  
experimento

**Miles / h**

de estructuras independientes  
en una sola GPU

# Cómo funciona: de la secuencia al ensamble



**Idea central:** cada residuo se representa como un marco rígido (traslación + rotación). El modelo parte de ruido aleatorio y, mediante pasos sucesivos de eliminación de ruido condicionados por los embeddings, llega a una estructura plausible. Repetir con otra semilla da otra muestra del ensamble.

# Entrenamiento en tres etapas



## **Etapas** Etapa 1

### **Preentrenamiento**

Estructuras de la AlphaFold DB, agrupadas para cubrir la diversidad de conformaciones de cada familia.



## **Etapas** Etapa 2

### **Ajuste con dinámica molecular**

Más de 200 ms de simulaciones MD, para que las poblaciones reflejen el equilibrio termodinámico.



## **Etapas** Etapa 3

### **Ajuste con experimentos**

Estabilidades de plegamiento medidas, para que la fracción plegada/desplegada concuerde con  $\Delta G$  experimental.

*Versiones del checkpoint: bioemu-v1.0 (preprint), bioemu-v1.1 (artículo en Science, usado aquí), bioemu-v1.2 (más MD y datos experimentales).*

# Entradas: una secuencia y unos pocos parámetros

| Parámetro      | Qué es                                            | Valor usado                   |
|----------------|---------------------------------------------------|-------------------------------|
| sequence       | Secuencia, archivo .fasta o .a3m (con MSA propio) | lbpchey_model0.fasta (339 aa) |
| num_samples    | Estructuras a generar antes del filtro            | 300                           |
| batch_size_100 | Lote para 100 aa; se escala por $(100/L)^2$       | 10 → lote efectivo 1          |
| model_name     | Checkpoint: bioemu-v1.0, v1.1 o v1.2              | bioemu-v1.1                   |
| filter_samples | Descarta choques y cadenas rotas                  | True                          |
| output_dir     | Carpeta de salida; permite reanudar               | bioemu/lbpchey                |

## Comando

```
python -m bioemu.sample \  
  --sequence lbpchey_model0.fasta \  
  --num_samples 300 \  
  --batch_size_100 10 \  
  --output_dir bioemu/lbpchey
```

**La secuencia se extrajo del modelo 0 de AlphaFold3.** BioEmu no usa coordenadas de entrada: el modelo de AF3 sirve como fuente de la secuencia y como referencia para el análisis.

# Salidas: del backbone al ensamble con todos los átomos

| Archivo                          | Contenido                                       | Generado por           |
|----------------------------------|-------------------------------------------------|------------------------|
| topology.pdb                     | Topología del backbone (N, CA, C, O)            | bioemu.sample          |
| samples.xtc                      | Coordenadas de las 246 muestras filtradas       | bioemu.sample          |
| batch_*.npz                      | Lotes crudos; permiten reanudar el muestreo     | bioemu.sample          |
| samples_sidechain_rec.pdb / .xtc | Cadenas laterales reconstruidas con HPacker     | bioemu.sidechain_relax |
| samples_md_equil.pdb / .xtc      | Ensamble minimizado con OpenMM (átomos pesados) | bioemu.sidechain_relax |

## Archivos derivados del análisis



rmsd\_lobulos.png ·  
apertura\_lobulos.png

Histogramas del análisis



repr\_cerrada / mediana / abierta.pdb

Estructuras representativas



ensamble\_lbpchey.pdb.gz

246 modelos ordenados para PyMOL

# Pipeline completo: unas 4 horas en una GPU



**run\_bioemu.sh** pasos 1-4 (instala el entorno si falta, extrae la secuencia, muestrea y relaja)

**analiza\_ensamble.py** RMSD por lóbulo, apertura y representativas

**prepara\_visualizacion.py** · **ver\_ensamble.pml** ensamble ordenado y película en PyMOL

# LBPCheY: un dominio CheY insertado en LBP


Mapa de dominios (339 residuos)



## La pregunta

Cada lóbulo pliega bien por separado, pero ¿se mueven uno respecto al otro?

Según el artículo de la quimera, el cristal muestra una orientación entre lóbulos distinta a la del diseño, y la calorimetría (DSC) sugiere un desplegamiento en dos etapas. Un ensamble permite explorar esa flexibilidad, que un modelo estático no muestra.



Modelo 0 de AlphaFold3 (pTM 0.81)

# Cada lóbulo conserva el plegamiento del modelo AF3

RMSD CheY

**0.81** Å

$\pm 0.30$  Å · mediana 0.73 Å

Prácticamente rígido en todo el ensamble

RMSD LBP

**2.30** Å

$\pm 1.87$  Å · mediana 1.83 Å

86.2% de las muestras < 3 Å; 12 muestras > 5 Å

RMSD Global


**3.56** Å

$\pm 2.32$  Å · mediana 2.88 Å

Mayor que cada lóbulo: hay movimiento entre ellos

**Lectura:** RMSD bajo en cada lóbulo y más alto en la estructura completa indica que ambos dominios pliegan bien y que lo que cambia es su orientación relativa.

# Los lóbulos se abren y cierran en un rango de 13 Å



**27.9 Å**

media del ensamble ( $\pm 2.0$ )


**23 – 36 Å**

rango observado

**27.8 Å**

modelo de AlphaFold3: cae en el centro

# LBP fijo, CheY se desplaza entre conformaciones



8 estructuras del ensemble, de la más cerrada a la más abierta, alineadas sobre LBP

## Verlo en PyMOL

```
pymol visualizacion/ver_ensamble.pml
```

```
mplay / mstop
```

película cerrada → abierta

```
set all_states, on
```

los 246 estados encimados

```
enable mediana
```

mostrar una representativa

*Las muestras son independientes, no una trayectoria: la película ordenada muestra la tendencia, no un camino temporal.*

# Qué tener en cuenta al interpretar el ensamble



## Sin información temporal

Las muestras son del equilibrio; no dan cinéticas ni rutas de transición.



## Solo backbone

Las cadenas laterales se reconstruyen después con HPicker y OpenMM.



## Una sola cadena

No modela complejos, ligandos ni cofactores.




## Filtro de calidad

Se descartaron 54 de 300 muestras (18%) por choques o cadena rota.



## Depende del MSA

La calidad de los embeddings depende del alineamiento de ColabFold.



## Costo práctico

Embeddings en CPU (~20 min) y relajación en un hilo (~3.5 h).

# Conclusiones y siguientes pasos

1

## Lóbulos estables

CheY (0.8 Å) y LBP (mediana 1.8 Å) conservan el plegamiento del modelo de AlphaFold3.

2

## Bisagra flexible

La distancia entre lóbulos varía de 23 a 36 Å: apoya la idea de una orientación relativa variable, aún por contrastar con el cristal.

3

## Pipeline reproducible

Scripts, tutorial y resultados en un repositorio. Cerca de 4 h en una GPU.

## Siguientes pasos

- Comparar el ensamble con la estructura cristalográfica (8Q52)
- Correr la variante LBPCheY-dbb y más muestras (1000) para mejorar la estadística
- Inspeccionar las muestras de LBP con RMSD > 5 Å (posible desplegamiento local)

# Referencias y recursos



## Artículo

Lewis S. et al. Scalable emulation of protein equilibrium ensembles with generative deep learning. Science 389 (2025).  
doi:10.1126/science.adv9817



## Código

github.com/microsoft/bioemu · pesos en huggingface.co/microsoft/bioemu (licencia MIT)



## Estructura de partida

AlphaFold Server (AlphaFold3). Salida sujeta a los AlphaFold Server Output Terms of Use, uso no comercial.



## Este trabajo

Repositorio jtuxman/lbpchey-bioemu: scripts, TUTORIAL.md, ensamble y figuras.