


BioEmu

Emulación de ensambles conformacionales de proteínas con IA generativa

Caso de estudio: la quimera LBPCheY



Modelo 0 de AlphaFold3 · LBP en gris, CheY en naranja

Contenido

01

El problema

Por qué una sola estructura no basta

02

Qué es BioEmu

Origen, alcance y entrenamiento

03

Cómo funciona

De la secuencia al ensamble

04

Entradas y salidas

Parámetros y archivos generados

05

Caso LBPCheY

Pipeline completo y resultados

06

Conclusiones

Limitaciones y siguientes pasos

Una estructura no describe cómo se mueve una proteína



Predicción estática

AlphaFold y similares

- Una conformación por modelo
- Muy precisa para el estado más probable
- No informa sobre poblaciones ni flexibilidad



Dinámica molecular

Simulación física

- Ensamble con base física
- Cambios lentos (μs – ms) cuestan semanas de GPU
- Difícil de escalar a muchas proteínas



BioEmu

Emulador generativo

- Ensamble de equilibrio desde la secuencia
- Miles de estructuras por hora en una GPU
- Muestras estadísticamente independientes

BioEmu: el ensamble de equilibrio desde la secuencia

Modelo generativo de difusión de Microsoft Research (Lewis et al., Science 2025).

Recibe una secuencia de una sola cadena y produce muestras independientes de su ensamble de equilibrio. Captura movimientos funcionales como bolsillos crípticos, desplegamiento local y rearrreglos entre dominios.

Código y pesos abiertos (licencia MIT):

github.com/microsoft/bioemu

>200 ms

de simulaciones de MD
integradas en el
entrenamiento

~1 kcal/mol

de error en energías libres
relativas frente a MD y
experimento

Miles / h

de estructuras independientes
en una sola GPU

Cómo funciona: de la secuencia al ensamble



Idea central: cada residuo se representa como un marco rígido (traslación + rotación). El modelo parte de ruido aleatorio y, mediante pasos sucesivos de eliminación de ruido condicionados por los embeddings, llega a una estructura plausible. Repetir con otra semilla da otra muestra del ensamble.

Entrenamiento en tres etapas



Etapas Etapa 1

Preentrenamiento

Estructuras de la AlphaFold DB, agrupadas para cubrir la diversidad de conformaciones de cada familia.



Etapas Etapa 2

Ajuste con dinámica molecular

Más de 200 ms de simulaciones MD, para que las poblaciones reflejen el equilibrio termodinámico.



Etapas Etapa 3

Ajuste con experimentos

Estabilidades de plegamiento medidas, para que la fracción plegada/desplegada concuerde con ΔG experimental.

Versiones del checkpoint: bioemu-v1.0 (preprint), bioemu-v1.1 (artículo en Science, usado aquí), bioemu-v1.2 (más MD y datos experimentales).

Entradas: una secuencia y unos pocos parámetros

Parámetro	Qué es	Valor usado
sequence	Secuencia, archivo .fasta o .a3m (con MSA propio)	lbpchey_model0.fasta (339 aa)
num_samples	Estructuras a generar antes del filtro	300
batch_size_100	Lote para 100 aa; se escala por $(100/L)^2$	10 → lote efectivo 1
model_name	Checkpoint: bioemu-v1.0, v1.1 o v1.2	bioemu-v1.1
filter_samples	Descarta choques y cadenas rotas	True
output_dir	Carpeta de salida; permite reanudar	bioemu/lbpchey

Comando

```
python -m bioemu.sample \
  --sequence lbpchey_model0.fasta \
  --num_samples 300 \
  --batch_size_100 10 \
  --output_dir bioemu/lbpchey
```

La secuencia se extrajo del modelo 0 de AlphaFold3. BioEmu no usa coordenadas de entrada: el modelo de AF3 sirve como fuente de la secuencia y como referencia para el análisis.

Salidas: del backbone al ensamble con todos los átomos

Archivo	Contenido	Generado por
topology.pdb	Topología del backbone (N, CA, C, O)	bioemu.sample
samples.xtc	Coordenadas de las 246 muestras filtradas	bioemu.sample
batch_*.npz	Lotes crudos; permiten reanudar el muestreo	bioemu.sample
samples_sidechain_rec.pdb / .xtc	Cadenas laterales reconstruidas con HPacker	bioemu.sidechain_relax
samples_md_equil.pdb / .xtc	Ensamble minimizado con OpenMM (átomos pesados)	bioemu.sidechain_relax

Archivos derivados del análisis



rmsd_lobulos.png ·
apertura_lobulos.png

Histogramas del análisis



repr_cerrada / mediana / abierta.pdb

Estructuras representativas



ensamble_lbpchey.pdb.gz

246 modelos ordenados para PyMOL

Pipeline completo: unas 4 horas en una GPU



run_bioemu.sh pasos 1-4 (instala el entorno si falta, extrae la secuencia, muestrea y relaja)

analiza_ensamble.py RMSD por lóbulo, apertura y representativas

prepara_visualizacion.py · **ver_ensamble.pml** ensamble ordenado y película en PyMOL

LBPCheY: un dominio CheY insertado en LBP


Mapa de dominios (339 residuos)



La pregunta

Cada lóbulo pliega bien por separado, pero ¿se mueven uno respecto al otro?

Según el artículo de la quimera, el cristal muestra una orientación entre lóbulos distinta a la del diseño, y la calorimetría (DSC) sugiere un desplegamiento en dos etapas. Un ensamble permite explorar esa flexibilidad, que un modelo estático no muestra.



Modelo 0 de AlphaFold3 (pTM 0.81)

Cada lóbulo conserva el plegamiento del modelo AF3

RMSD CheY

0.81 Å

± 0.30 Å · mediana 0.73 Å

Prácticamente rígido en todo el ensamble

RMSD LBP

2.30 Å

± 1.87 Å · mediana 1.83 Å

86.2% de las muestras < 3 Å; 12 muestras > 5 Å

RMSD Global


3.56 Å

± 2.32 Å · mediana 2.88 Å

Mayor que cada lóbulo: hay movimiento entre ellos

Lectura: RMSD bajo en cada lóbulo y más alto en la estructura completa indica que ambos dominios pliegan bien y que lo que cambia es su orientación relativa.

Los lóbulos se abren y cierran en un rango de 13 Å



27.9 Å

media del ensamble (± 2.0)


23 – 36 Å

rango observado

27.8 Å

modelo de AlphaFold3: cae en el centro

LBP fijo, CheY se desplaza entre conformaciones



8 estructuras del ensemble, de la más cerrada a la más abierta, alineadas sobre LBP

Verlo en PyMOL

```
pymol visualizacion/ver_ensamble.pml
```

```
mplay / mstop
```

película cerrada → abierta

```
set all_states, on
```


los 246 estados encimados

```
enable mediana
```

mostrar una representativa

Las muestras son independientes, no una trayectoria: la película ordenada muestra la tendencia, no un camino temporal.

Una conformación dominante y dos giros de CheY




Conf.	Muestras	Población (IC 95%)	ΔG kcal/mol (IC 95%)	Giro de CheY
1	172	69.9% (64-76)	0 (referencia)	$-3.5 \pm 12^\circ$
2	54	22.0% (17-27)	+0.69 (0.52-0.89)	$+32 \pm 21^\circ$
3	20	8.1% (5-12)	+1.28 (1.04-1.59)	$-44 \pm 47^\circ$

Ambos lóbulos plegados en 246/246 muestras (contactos nativos ≥ 0.65 , criterio de BioEmu): ΔG de desplegamiento > 3.3 kcal/mol, el máximo medible con 246 muestras.

$\Delta G = -kT \cdot \ln(p_i / p_1)$ 300 K · conformaciones por PCA + k-means de la posición de CheY · IC por bootstrap. BioEmu solo da estructuras: las poblaciones salen de contar muestras.

Superficie de energía libre: el mínimo coincide con AF3

Superficie de energía libre de LBPCheY (BioEmu, 246 muestras, 300 K)



Mínimo en AF3

La estrella (modelo 0) cae en el pozo más profundo de ambas superficies.

Sin apertura discreta

La distancia entre lóbulos forma un solo pozo amplio (~27-28 Å).

Giros opuestos

Conf. 2 gira +32° y conf. 3 -44°, a ~1-1.5 kcal/mol.

$F = -kT \cdot \ln p$ (kernel gaussiano), curvas cada 0.5 kcal/mol. Estilo de la Fig. 3 del artículo de BioEmu; aquí con PCA y variables físicas en lugar de TICA (no hay MD).

Qué tener en cuenta al interpretar el ensamble



Sin información temporal

Las muestras son del equilibrio; no dan cinéticas ni rutas de transición.



Solo backbone

Las cadenas laterales se reconstruyen después con HPacker y OpenMM.



Una sola cadena

No modela complejos, ligandos ni cofactores.




Filtro de calidad

Se descartaron 54 de 300 muestras (18%) por choques o cadena rota.



Depende del MSA

La calidad de los embeddings depende del alineamiento de ColabFold.



Costo práctico

Embeddings en CPU (~20 min) y relajación en un hilo (~3.5 h).

Conclusiones y siguientes pasos

1

Lóbulos estables

CheY (0.8 Å) y LBP (mediana 1.8 Å) conservan el plegamiento del modelo de AlphaFold3.

2

Bisagra flexible

70% en la orientación de AF3; CheY gira $+32^\circ$ (22%) o -44° (8%) a solo 0.7–1.3 kcal/mol. Por contrastar con el cristal.

3

Pipeline reproducible

Scripts, tutorial y resultados en un repositorio. Cerca de 4 h en una GPU.

Siguientes pasos

- Comparar el ensamble con la estructura cristalográfica (8Q52)
- Correr la variante LBPCheY-dbb y más muestras (1000) para mejorar la estadística
- Inspeccionar las muestras de LBP con RMSD > 5 Å (posible desplegamiento local)

Referencias y recursos



Artículo

Lewis S. et al. Scalable emulation of protein equilibrium ensembles with generative deep learning. Science 389 (2025).
doi:10.1126/science.adv9817



Código

github.com/microsoft/bioemu · pesos en huggingface.co/microsoft/bioemu (licencia MIT)



Estructura de partida

AlphaFold Server (AlphaFold3). Salida sujeta a los AlphaFold Server Output Terms of Use, uso no comercial.



Este trabajo

Repositorio jtuxman/lbpchey-bioemu: scripts, TUTORIAL.md, ensamble y figuras.